

## 第八讲 UMVUE

例：设  $X \sim N(\mu, \sigma^2)$ ,  $\sigma^2$  已知,  $\mu$  未知, 证明:  $\bar{X}$  是  $\mu$  的 UMVUE

证:  $\forall \varphi(X_1, \dots, X_n)$  满足  $E\varphi = 0$

$$\text{使 } E\bar{X} \cdot \varphi = 0$$

$$0 = E\varphi(X_1, \dots, X_n) = \int \dots \int \varphi(x_1, \dots, x_n) \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\right\} dx_1 \dots dx_n$$

两边关于  $\mu$  求导

$$0 = \int \dots \int n(\bar{x} - \mu) \varphi(x_1, \dots, x_n) \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\right\} dx_1 \dots dx_n$$

例 6.4.2 设  $x_1, x_2, \dots, x_n$  是来自指数分布  $Exp(1/\theta)$  的样本, 则根据因子分解定理

可知,  $T = x_1 + x_2 + \dots + x_n$  是  $\theta$  的充分统计量, 由于  $E(T) = n\theta$ , 所以  $\bar{x} = T/n$  是  $\theta$  的无偏估计. 设  $\varphi = \varphi(x_1, x_2, \dots, x_n)$  是  $\theta$  的任一无偏估计, 则

$$E(\varphi(x_1, \dots, x_n)) = \int_0^\infty \dots \int_0^\infty \varphi(x_1, \dots, x_n) \cdot \prod_{i=1}^n \left\{\frac{1}{\theta} \cdot e^{-x_i/\theta}\right\} dx_1 \dots dx_n = 0,$$

即

$$\int_0^\infty \dots \int_0^\infty \varphi(x_1, \dots, x_n) \cdot e^{-(x_1 + \dots + x_n)/\theta} dx_1 \dots dx_n = 0,$$

两端对  $\theta$  求导, 得

$$\int_0^\infty \dots \int_0^\infty \frac{n\bar{x}}{\theta^2} \varphi(x_1, \dots, x_n) \cdot e^{-(x_1 + \dots + x_n)/\theta} dx_1 \dots dx_n = 0.$$

这说明  $E(\bar{x} \cdot \varphi) = 0$ , 从而

$$\text{Cov}(\bar{x}, \varphi) = E(\bar{x} \cdot \varphi) - E(\bar{x}) \cdot E(\varphi) = 0.$$

由定理 6.4.1,  $\bar{x}$  是  $\theta$  的 UMVUE.



## 2. (Rao - Blackwell 定理)

定理 6.4.2 设总体概率函数是  $p(x; \theta)$ ,  $x_1, x_2, \dots, x_n$  是其样本,  $T = T(x_1, x_2, \dots, x_n)$  是  $\theta$  的充分统计量, 则对  $\theta$  的任一无偏估计  $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ , 令  $\tilde{\theta} = E(\hat{\theta}|T)$ , 则  $\tilde{\theta}$  也是  $\theta$  的无偏估计, 且

$$\hat{\theta}^* = \tilde{\theta}$$

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta}).$$

证明 由于  $T = T(x_1, x_2, \dots, x_n)$  是充分统计量, 故而  $\tilde{\theta} = E(\hat{\theta}|T)$  与  $\theta$  无关, 因此它也是  $\theta$  的一个估计(统计量), 根据重期望公式, 有

$$E(\tilde{\theta}) = E[E(\hat{\theta}|T)] = E(\hat{\theta}) = \theta,$$

故  $\tilde{\theta}$  是  $\theta$  的无偏估计. 再考察其方差

$$\text{Var}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = E(\hat{\theta}^2) - E(\hat{\theta})^2 = E(\hat{\theta}^2) - \theta^2 = E(\hat{\theta}^2) - E(E(\hat{\theta}|T)) = E(\hat{\theta}^2|T) - E(E(\hat{\theta}|T)|T) = E(\tilde{\theta}^2|T) - E(\tilde{\theta}|T)^2 = \text{Var}(\tilde{\theta}),$$

由于

$$E[(\hat{\theta} - \tilde{\theta})(\tilde{\theta} - \theta)] = E[E[(\hat{\theta} - \tilde{\theta})(\tilde{\theta} - \theta)|T]] = E[(\tilde{\theta} - \theta)E[(\hat{\theta} - \tilde{\theta})|T]] = 0,$$

$$\text{由此即有 } E[(\hat{\theta} - \tilde{\theta})^2] = E[(\hat{\theta} - \tilde{\theta})^2|T] = E[\tilde{\theta}^2|T] - E(\tilde{\theta}|T)^2 = 0.$$

$$\text{Var}(\hat{\theta}) = E(\hat{\theta}^2) - E(\hat{\theta})^2 = E(\tilde{\theta}^2) - E(\tilde{\theta})^2 = \text{Var}(\tilde{\theta}).$$

由于上式右端第一项非负, 这就证明了第二个结论.

## 4. 唯一性证明:

下是充分完备的,  $\forall E\hat{\theta}_1 = \theta, E\hat{\theta}_2 = \theta$

$$E[\hat{\theta}_1|T] = \hat{\theta}_1^*, E[\hat{\theta}_2|T] = \hat{\theta}_2^*$$

$$E\hat{\theta}_1^* = \theta, E\hat{\theta}_2^* = \theta$$

求重期望

$$E[E(\hat{\theta}_1|T)] - E[E(\hat{\theta}_2|T)] = 0$$

$$E\{E(\hat{\theta}_1|T) - E(\hat{\theta}_2|T)\} = 0$$

$$\underbrace{g_1(T) - g_2(T)}_{g(T)} \quad T \text{ 充分完备}$$

$$\Rightarrow P\{g(T) = 0\} = 1$$

已经在  $T$  的条件下了

$$E(\tilde{\theta}|T) = \theta$$

$$\text{因为 } \tilde{\theta} = E(\hat{\theta}|T)$$

找到充分完备统计量  $T$   
 构造  $g(T)$ , 使  $Eg(T) = \theta$   
 则  $g(T)$  就是 UMVUE

定理 6.4.1 设  $X = (x_1, x_2, \dots, x_n)$  是来自某总体的一个样本， $\hat{\theta} = \hat{\theta}(X)$  是  $\theta$  的一个无偏估计， $\text{Var}(\hat{\theta}) < \infty$ 。则  $\hat{\theta}$  是  $\theta$  的 UMVUE 的充要条件是，对任意一个满足  $E(\varphi(X)) = 0$  和  $\text{Var}(\varphi(X)) < \infty$  的  $\varphi(X)$ ，都有

$$\text{Cov}(\hat{\theta}, \varphi) = 0, \quad \forall \theta \in \Theta.$$

这个定理表明： $\theta$  的 UMVUE 必与任一零的无偏估计不相关，反之亦然，这是 UMVUE 的重要特征。

## 第八讲 一致最小方差无偏估计

### 1. 一致最小方差无偏估计(UMVUE)的定义.

$$\text{满足 } E\hat{\theta}^* = \theta$$

设  $\hat{\theta}^*$  是  $\theta$  的无偏估计，若对于  $\theta$  的任意一个无偏估计  $\hat{\theta}$ ，都有  $D\hat{\theta}^* \leq D\hat{\theta}, \forall \theta \in \Theta$ ，则称  $\hat{\theta}^*$  是  $\theta$  的一致最小方差无偏估计。记为 UMVUE。 $\Leftrightarrow$   $\forall \theta \in \Theta, \exists \hat{\theta}^*, \text{ 满足 } E\hat{\theta}^* = \theta, \text{ 且 } D\hat{\theta}^* \leq D\hat{\theta}$ ，则称  $\hat{\theta}^*$  是  $\theta$  的一致最小方差无偏估计。

### 2. (Rao-Blackwell 定理) 书 P289 定理 6.4.2

设  $(X_1, \dots, X_n)$  为取自总体  $X \sim F(x; \theta)$  的样本， $\theta \in \Theta$  未知，若  $T = T(X_1, \dots, X_n)$  是  $\theta$  的充分统计量， $\hat{\theta}$  是  $\theta$  的任一无偏估计，

记  $\hat{\theta}^* = E[\hat{\theta} | T]$ ，则有  $E\hat{\theta}^* = \theta, \forall \theta \in \Theta$ ，且  $D\hat{\theta}^* \leq D\hat{\theta}, \forall \theta \in \Theta$ 。（为什么  $E[\hat{\theta} | T]$  是一个估计量？）

（即把一个无偏估计  $\hat{\theta}$  对某个充分统计量  $T$  求条件期望  $E(\hat{\theta} | T)$  可获得一个更有效的无偏估计。）

3. 所以  $\theta$  的一致最小方差无偏估计一定是在  $\theta$  的充分的无偏估计类里寻找。（为什么？）

进一步，如果充分无偏估计是唯一的，那么它一定就是  $\theta$  的一致最小方差无偏估计（UMVUE）

4. 问：什么条件下  $\theta$  的充分无偏估计是唯一的呢？

设  $(X_1, \dots, X_n)$  为取自总体  $X \sim F(x; \theta)$  的样本， $\theta \in \Theta$  未知，若  $T = T(X_1, \dots, X_n)$  是  $\theta$  的充分完备统计量， $\hat{\theta}$  是  $\theta$  的任一无偏估计，记  $\hat{\theta}^* = E[\hat{\theta} | T]$ ，则  $\hat{\theta}^*$  是  $\theta$  的一致最小方差无偏估计。

⑤ 寻找 UMVUE 的方法：先寻找一个 充分完备统计量  $T = T(X_1, \dots, X_n)$  和  $\theta$  的一个 无偏估计  $g(T)$ ，则  $g(T)$  就是  $\theta$  的 UMVUE。

### 6. 有效估计一定是 UMVUE，但 UMVUE 不一定是有效估计。

例：设总体  $X \sim N(\mu, 1)$ ，则  $\mu^2$  的 UMVUE  $T = \bar{X}^2 - 1/n$  并不是  $\mu^2$  的有效估计。

证： $f(x; \mu) = \left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{1}{2}(x-\mu)^2}$

### ① 找充分完备统计量

$$\Rightarrow L(\mu) = \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left\{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\right\} = \underbrace{\left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{n\mu^2}{2}}}_{C(\mu)} \cdot \exp\left\{\underbrace{\sqrt{\mu^2} \left(\sum_{i=1}^n x_i\right)}_{b(\mu) T}\right\} \cdot \underbrace{e^{-\frac{1}{2} \sum_{i=1}^n x_i^2}}_{h(x_1, \dots, x_n)}$$

$$\triangleq C(\mu^2) \exp\{b(\mu^2)T\} h(x_1, \dots, x_n) \quad (\text{指数型分布族})$$

所以  $\sum_{i=1}^n x_i = n\bar{X}$  是未知参数  $\mu^2$  的充分完备统计量。

### ② 判断是否为无偏估计

又因为  $E[T] = E[\bar{X}^2 - 1/n] = E[\bar{X}^2] - 1/n = D\bar{X}(\frac{2}{n}) + E[X]^2 - 1/n = \mu^2 - 1/n = \mu^2$ ，且  $T = \bar{X}^2 - 1/n$  又是

$\sum_{i=1}^n x_i = n\bar{X}$  的函数，所以  $T = \bar{X}^2 - 1/n$  是  $\mu^2$  的 UMVUE。

$$\text{计算 } \ln f(X; \mu) = \ln\left(\frac{1}{\sqrt{2\pi}}\right) - \frac{1}{2}(X - \mu)^2, \frac{\partial \ln f(X; \mu)}{\partial \mu} = (X - \mu), \frac{\partial^2 \ln f(X; \mu)}{\partial \mu^2} = -1$$

$$\text{费希尔信息量 } I(\mu) = -E\left[\frac{\partial^2 \ln f(X; \mu)}{\partial \mu^2}\right] = 1, \text{ 所以 } \mu^2 \text{ 的 R-C 下界为 } \frac{[g'(\mu)]^2}{nI(\mu)} = \frac{4\mu^2}{n}.$$

进一步， $DT = D[\bar{X}^2 - 1/n] = E\bar{X}^4 - (E\bar{X}^2)^2 = \frac{2}{n^2} + \frac{4\mu^2}{n} > \frac{4\mu^2}{n}$ 。所以  $T$  不是  $\mu^2$  的有效估计。

1. 设总体  $X \sim \Gamma(\alpha, \beta)$  分布, 其中  $\alpha > 0$  已知,  $\beta > 0$  未知. 试求  $g(\beta) = 1/\beta$  的极大似然估计, UMVUE, 有效估计。

$$f(x; \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} e^{-\beta x} x^{\alpha-1}, \quad x > 0$$

$$L(\beta) = \frac{\beta^{n\alpha}}{[\Gamma(\alpha)]^n} e^{-\beta \sum_{i=1}^n x_i} \prod_{i=1}^n x_i^{\alpha-1}$$

$$\ln L(\beta) = n\alpha \ln \beta - n \ln \Gamma(\alpha) - \beta \sum_{i=1}^n x_i + (\alpha-1) \sum_{i=1}^n \ln x_i$$

$$\frac{\partial \ln L(\beta)}{\partial \beta} = \frac{n\alpha}{\beta} - \sum_{i=1}^n x_i = 0$$

$$\hat{g}(\beta) = \left( \frac{1}{\beta} \right)_{MLE} = \frac{\bar{x}}{\alpha}$$

$$L(\beta) = \underbrace{\frac{\beta^{n\alpha}}{[\Gamma(\alpha)]^n}}_{C(\beta)} \exp \left\{ -\beta \sum_{i=1}^n x_i \right\} \underbrace{\prod_{i=1}^n x_i^{\alpha-1}}_{h(x_1, \dots, x_n)}$$

由指指数型分布族可知  $\sum_{i=1}^n x_i$  是  $\frac{1}{\beta}$  的充分完备统计量。

$$E\left[\sum_{i=1}^n x_i\right] = nE[X] = n\frac{\alpha}{\beta}$$

$$E\left[\frac{1}{n} \sum_{i=1}^n x_i \mid \sum_{i=1}^n x_i\right] = \frac{1}{n\alpha} \sum_{i=1}^n x_i, \text{ 而 } \frac{\sum_{i=1}^n x_i}{n\alpha} = \frac{\bar{x}}{\alpha} \text{ 为 UMVUE}$$

$$\frac{\partial \ln L(\beta)}{\partial \beta} = \frac{n\alpha}{\beta} - \sum_{i=1}^n x_i = -n\alpha \left[ \frac{\bar{x}}{\alpha} - \frac{1}{\beta} \right]$$

$$E\left[\frac{\bar{x}}{\alpha}\right] = \frac{1}{\beta}, \text{ 则 } \frac{\bar{x}}{\alpha} \text{ 是 } \frac{1}{\beta} \text{ 的有效估计 } \square$$

$$2. \text{ 设总体 } \xi \text{ 的密度函数为 } f(x; \theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1, \theta > 0 \\ 0, & \text{else} \end{cases}$$

(1) 求可估函数  $1/\theta$  的极大似然估计量; (2) 求可估函数  $1/\theta$  的有效估计量;

(3) 证明  $1/\theta$  的极大似然估计量也是  $1/\theta$  的一致最小方差无偏估计量。

$$\text{解: (1) } \because L(\theta) = \theta^n \prod_{i=1}^n x_i^{\theta-1} \Rightarrow \ln L(\theta) = n \ln \theta + (\theta-1) \ln \prod_{i=1}^n x_i \Rightarrow \text{令 } \frac{\partial \ln L(\theta)}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i = 0$$

$$\left( \frac{1}{\theta} \right)_{MLE} = -\frac{1}{n} \sum_{i=1}^n \ln x_i。 \text{ 同时易知 } \frac{\partial \ln L(\theta)}{\partial \theta} = -n \left[ -\frac{1}{n} \sum_{i=1}^n \ln x_i - \frac{1}{\theta} \right], \text{ 且 } E\left[ -\frac{1}{n} \sum_{i=1}^n \ln x_i \right] = -\frac{1}{n} n E \ln \xi = \frac{1}{\theta},$$

$$\text{其中 } \ln \xi = \int_0^1 \ln x \theta x^{\theta-1} dx = \int_0^1 \ln x d x^\theta = x^\theta \ln x \Big|_0^1 - \int_0^1 x^\theta \frac{1}{x} dx = 0 - \frac{1}{\theta} x^\theta \Big|_0^1 = -\frac{1}{\theta}。$$

可见  $-\frac{1}{n} \sum_{i=1}^n \ln x_i$  就是  $\frac{1}{\theta}$  的有效估计。则它也就是一致最小方差无偏估计。

另解:  $\because L(\theta) = \theta^n \prod_{i=1}^n x_i^{\theta-1} = \theta^n \exp\{(\theta-1) \ln(\prod_{i=1}^n x_i)\} = (1/\theta)^{-n} \exp\left\{[(1/\theta)^{-1} - 1] \sum_{i=1}^n \ln x_i\right\}$ , 由指指数型分布族的

定义可知  $\sum_{i=1}^n \ln \xi_i$  是  $\frac{1}{\theta}$  的充分完备统计量。又因为  $E[\sum_{i=1}^n \ln \xi_i] = -\frac{n}{\theta} \Rightarrow E[-\frac{1}{n} \sum_{i=1}^n \ln \xi_i] = \frac{1}{\theta}$ 。

则  $\left(\frac{\hat{\theta}}{\theta}\right)^* = E\left[-\frac{1}{n} \sum_{i=1}^n \ln \xi_i \middle| \sum_{i=1}^n \ln \xi_i\right] = -\frac{1}{n} \sum_{i=1}^n \ln \xi_i$  就是  $\frac{1}{\theta}$  的一致最小方差无偏估计。



3) 设样本  $X_1, \dots, X_n$  取自总体  $X \sim N(0, \sigma^2)$ , (1) 证明:  $T = \sum_{i=1}^n X_i^2$  是未知参数  $\sigma^2$  的充分完备统计量;

(2) 求  $\sigma^2$  的 UMVUE; (3) 求  $\sigma^2$  的有效估计。

$$(1) X \sim N(0, \sigma^2); f(x; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2}{2\sigma^2}}$$

$$L(\sigma^2) = \prod_{i=1}^n f(X_i; \sigma^2) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n X_i^2 \right\}$$

由指数型分布定义知  $T = \sum_{i=1}^n X_i^2$  为  $\sigma^2$  的充分完备统计量  $\square$

$$(2) E\left[\frac{\sum_{i=1}^n X_i^2}{n}\right] = EX^2 = [DX + (EX)^2] = \sigma^2$$

则  $\frac{1}{n} \sum_{i=1}^n X_i^2$  为  $\sigma^2$  的 UMVUE  $\square$

$$(3) \ln L(\sigma^2) = -n \ln \sqrt{2\pi} \sqrt{\sigma^2} - \frac{1}{2\sigma^2} \sum_{i=1}^n X_i^2$$

$$= -n \ln \sqrt{2\pi} - \frac{1}{2} n \ln \sigma^2 + \frac{1}{2\sigma^2} \sum_{i=1}^n X_i^2$$

$$\frac{\partial \ln L(\sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n X_i^2 = \underbrace{\frac{n}{2\sigma^4}}_{C(\sigma^2)} \left( \underbrace{\frac{\sum_{i=1}^n X_i^2}{n}}_T - \underbrace{\sigma^2}_{g(\theta)} \right)$$

$$\triangleq C(\sigma^2)(T - g(\theta))$$

$\frac{1}{n} \sum_{i=1}^n X_i^2$  为  $\sigma^2$  的有效估计  $\square$

4. 设样本  $(X_1, X_2, \dots, X_n)$  取自总体  $U(0, \theta), \theta > 0$ , 证明: (1) 该均匀分布族不是指数型分布族; (2)  $X_{(n)}$  是  $\theta$  的充分统计量;(利用因子分解定理验证); (3)  $X_{(n)}$  是  $\theta$  的完备统计量.(利用完备统计量的定义证明) (P70 例 7.3.8); (4) 求  $\theta$  的一致最小方差无偏估计 UMVUE.

$$(1) f(x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 \leq x \leq \theta \\ 0, & \text{else} \end{cases}, \quad F(x) = \begin{cases} 0, & x < 0 \\ \frac{x}{\theta}, & 0 \leq x \leq \theta \\ 1, & x > \theta \end{cases}$$

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \frac{1}{\theta^n} \prod_{\{x_{(1)} \geq 0, x_{(n)} \leq \theta\}} \text{ 不是指数型分布族}$$

$$(2) L(\theta) = \underbrace{\frac{1}{\theta^n} \prod_{\{x_{(n)} \leq \theta\}}}_{g(T, \theta)} \underbrace{1}_{h(x_1, \dots, x_n)}$$

$$(3) f_{X_{(n)}}(x; \theta) = n [F(x)]^{n-1} f(x) = n \cdot \frac{x^{n-1}}{\theta^{n-1}} \cdot \frac{1}{\theta} = \frac{n x^{n-1}}{\theta^n}$$

$$\text{若 } E[g(X_{(n)}) | \theta] = \int_0^\theta g(x) \frac{n x^{n-1}}{\theta^n} dx = 0, \forall \theta > 0$$

$$\Rightarrow \int_0^\theta g(x) x^{n-1} dx = 0 \quad \forall \theta > 0$$

$$\text{两边同除有 } g(\theta) \theta^{n-1} = 0, \forall \theta > 0$$

$$\Rightarrow g(x) = 0, \forall x > 0 \Rightarrow P(g(X_{(n)}) = 0 | \theta) = 1, \forall \theta > 0$$

$X_{(n)}$  是  $\theta$  的充分完备统计量  $\square$

$$(4) E(X_{(n)}) = \int_0^\theta x \frac{n x^{n-1}}{\theta^n} dx = \frac{n \theta}{n+1}$$

$$E\left(\frac{n+1}{n} X_{(n)}\right) = \theta \Rightarrow \frac{n+1}{n} X_{(n)} \text{ 是 } \theta \text{ 的无偏估计量 } \square$$

5. 设总体  $\xi \sim N(a, \sigma^2)$ ,  $\xi_1, \dots, \xi_n$  为  $\xi$  的样本,  $a$  为已知, 证明  $\hat{\sigma} \triangleq \frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |\xi_i - a|$  为  $\sigma$  的无偏估计量, 且有效率为  $\frac{1}{\pi-2}$ 。

证明: 因为  $\xi_i \sim N(a, \sigma^2)$ ,  $\xi_i - a \sim N(0, \sigma^2)$ ,  $\Rightarrow E|\xi_i - a| = \sqrt{2/\pi}\sigma = \int_{-\infty}^{+\infty} |x| \frac{1}{\sqrt{\pi}} e^{-\frac{x^2}{2\sigma^2}} dx$

$$\therefore E\left[\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |\xi_i - a|\right] = \frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n E|\xi_i - a| = \frac{1}{n} \sqrt{\frac{\pi}{2}} n \sqrt{\frac{2}{\pi}} \sigma = \sigma, \quad \therefore \frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |\xi_i - a| \text{ 是 } \sigma \text{ 的无偏估计。}$$

$$\because \xi_i \sim N(a, \sigma^2), \therefore L(\sigma) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2} \Rightarrow \boxed{\frac{\partial \ln L(\sigma)}{\partial \sigma}} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - a)^2 = \frac{n}{\sigma^3} \left[ \frac{1}{n} \sum_{i=1}^n (x_i - a)^2 - \sigma^2 \right]$$

式中为6, 没有转6的形式

不能表示成  $C(\sigma)[T(X_1, \dots, X_n) - \sigma]$  的形式, 可见  $\sigma$  的有效估计量并不存在。

$$\ln f(\xi; \sigma) = -\ln 2\pi - \ln \sigma - \frac{1}{2\sigma^2} (\xi - a)^2 \Rightarrow \frac{\partial \ln f(\xi; \sigma)}{\partial \sigma} = -\frac{1}{\sigma} + \frac{1}{\sigma^3} (\xi - a)^2 \Rightarrow \frac{\partial^2 \ln f(\xi; \sigma)}{\partial \sigma^2} = \frac{1}{\sigma^2} - \frac{3}{\sigma^4} (\xi - a)^2$$

$$\therefore I(\sigma) = -E\left[\frac{\partial^2 \ln f(\xi; \sigma)}{\partial \sigma^2}\right] = -\frac{1}{\sigma^2} + \frac{3}{\sigma^4} E(\xi - a)^2 = \frac{2}{\sigma^2}, \quad \text{于是计算 R-C 不等式的方差下界} = \frac{1}{nI(\sigma)} = \frac{\sigma^2}{2n}.$$

$$\therefore D\left[\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |\xi_i - a|\right] = \frac{1}{n^2} \frac{\pi}{2} \sum_{i=1}^n D|\xi_i - a| = \frac{\pi}{2n^2} n \left[ E|\xi_i - a|^2 - (E|\xi_i - a|)^2 \right] = \frac{\pi}{2n} \left[ D\xi_i - \left( \sqrt{\frac{2}{\pi}} \sigma \right)^2 \right] = \frac{\pi-2}{2n} \sigma^2$$

$$\therefore \frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |\xi_i - a| \text{ 的效率为 } e = \frac{\sigma^2}{2n} / \frac{\pi-2}{2n} \sigma^2 = \frac{1}{\pi-2}.$$

# 总结:

## ① 充分统计量:

### ★ 2. 因子分解定理: 判断充分统计量的简单准则 (Fisher-Neyman 准则)

设  $(X_1, \dots, X_n)$  为取自总体  $X \sim p(x; \theta)$  的一个简单随机样本, (其中对离散型总体  $p(x; \theta)$  对应的是概率分布律函数, 对连续型总体对应的是密度函数)。记  $L(x; \theta)$  为样本的联合分布, 则统计量  $T = T(X_1, \dots, X_n)$  是  $\theta$  的充分统计量, 等价于

$$L(x; \theta) = \prod_{i=1}^n p(x_i; \theta) = h(x_1, x_2, \dots, x_n) g(T(x_1, x_2, \dots, x_n); \theta), \quad \text{其中 } h \text{ 是关于 } (x_1, \dots, x_n) \text{ 的非负函数且与 } \theta \text{ 无关}, g \text{ 是仅通过统计量 } T \text{ 依赖于 } (x_1, \dots, x_n) \text{ 的函数。}$$

$$\Leftrightarrow L(x; \theta) = \prod_{i=1}^n p(x_i; \theta) = h(x_1, x_2, \dots, x_n) \underbrace{g(T(x_1, x_2, \dots, x_n); \theta)}_{\text{包围}}$$

## ② 完备统计量

### 二. 完备统计量

1. 完备分布函数族的定义: 设总体  $X \sim \{F(x; \theta), \theta \in \Theta\}$ , 若对于任意的一个满足  $E[g(X)|\theta] = 0$ , 对于任意的  $\theta \in \Theta$  的 r.v.  $g(X)$ , 总有  $P[g(X)=0|\theta]=1$ , 对于任意的  $\theta \in \Theta$ , 则称  $\{F(x; \theta), \theta \in \Theta\}$  是完备的分布函数族。

2. 完备统计量的定义: 设  $(X_1, \dots, X_n)$  是来自总体  $X \sim \{F(x; \theta), \theta \in \Theta\}$  的一个样本, 若统计量  $T = T(X_1, \dots, X_n)$  的分布函数族  $\{F_T(t; \theta), \theta \in \Theta\}$  是完备的分布函数族, 则称  $T = T(X_1, \dots, X_n)$  为完备统计量。

可见,  $P[g_1(T) = g_2(T)|\theta] = 1, \forall \theta \in \Theta \Leftrightarrow E[g_1(T)|\theta] = E[g_2(T)|\theta], \forall \theta \in \Theta$   
“完备统计量”意味着“a.s.相等”等价于 期望相等

若  $\forall E[g(T)|\theta] = 0 \Rightarrow P[g(T)=0] = 1$ , 则称  $T$  为完备统计量。

## ③ 充分完备统计量:

### ★ 5. (充分完备统计量的判断定理)

设总体  $X$  的分布是指数型分布族, 即样本联合分布可以表示成

$$L(x_1, x_2, \dots, x_n; \theta) \\ = C(\theta) \exp \left\{ \sum_{i=1}^m b_j(\theta) T_j(x_1, x_2, \dots, x_n) \right\} h(x_1, x_2, \dots, x_n)$$

其中  $\theta = (\theta_1, \dots, \theta_m)^T$ ,  $T = (T_1(x_1, \dots, x_n), \dots, T_m(x_1, \dots, x_n))^T$ , 则  $T$  是  $\theta$  的充分完备统计量。

## ④ 有效估计:

### ★ 3. (书 P39 推论 2.2.4) 有效估计的充要条件: 在定理 2.2.1 的条件下, (i) 可估函数 $g(\theta)$ 的有效估计量存在且为无

偏估计  $T(X_1, X_2, \dots, X_n)$  的充要条件是  $\frac{\partial \ln L(\theta)}{\partial \theta}$  可以化为形式  $C(\theta)[T(X_1, \dots, X_n) - g(\theta)], a.s.$ ;

判断是否为有效估计:

$$\textcircled{1} \quad p(x; \theta) / f(x; \theta)$$

$$\textcircled{2} \quad L(x_1, \dots, x_n; \theta)$$

$$\textcircled{3} \quad \ln L(x_1, \dots, x_n; \theta)$$

$$\textcircled{4} \quad \frac{\partial \ln L(x_1, \dots, x_n; \theta)}{\partial \theta} \triangleq C(\theta) [T(x_1, \dots, x_n) - g(\theta)]$$

有效估计

求是否是达到 R-C 下界的无偏估计

① 密度函数： $f(x; \theta) / p(x; \theta)$

② 取对数： $\ln p(x; \theta)$

③ 求偏导： $\frac{\partial \ln p(x; \theta)}{\partial \theta}$

④ 求 Fisher 信息量：

$$I(\theta) = E \left[ \frac{\partial \ln p(x; \theta)}{\partial \theta} \right]^2, J(\theta) = -E \left[ \frac{\partial^2 \ln p(x; \theta)}{\partial \theta^2} \right]$$

⑤ 求 R-C 下界：

$$\frac{[g'(\theta)]^2}{n I(\theta)}, \text{ 其中 } g(\theta) \text{ 为要估计的参数}$$

⑥ 求  $D(T(x_1, \dots, x_n))$ , 其中  $T(x_1, \dots, x_n)$  是  $g(\theta)$  的无偏估计

⑦ 比较 R-C 下界  $\geq D(T(x_1, \dots, x_n))$

⑤ UMVUE:

⑤ 寻找 UMVUE 的方法：先寻找一个 充分完备统计量  $T = T(X_1, \dots, X_n)$  和  $\theta$  的一个 无偏估计  $g(T)$ , 则

$g(T)$  就是  $\theta$  的 UMVUE.

6. 有效估计一定是 UMVUE, 但 UMVUE 不一定是有有效估计。